HO
GENT

OOSDII

Strings en reguliere expressies

Table of Contents

1. Doelstellingen . . . 1
2. Inleiding . . . 1
3. Fundamenten van karakters en Strings . . . 1
4. Klasse String . . . 2
    4.1. String constructoren . . . 2
    4.2. String literal versus String Object . . . 2
    4.3. String methodes . . . 3
    4.4. Strings vergelijken . . . 3
    4.5. Karakters en substrings uit Strings . . . 4
    4.6. Concateneren van Strings . . . 5
    4.7. Andere String-methodes . . . 5
    4.8. String methode valueOf . . . 5
5. Klasse StringBuilder . . . 5
    5.1. StringBuilder constructors . . . 6
    5.2. StringBuilder methoden . . . 6
    5.3. Methodes voor karakterbewerkingen . . . 7
    5.4. Append methodes . . . 7
    5.5. Tussenvoeg- en verwijdermethodes . . . 7
6. Klasse Character . . . 8
7. Tokenizing Strings . . . 8
8. Reguliere expressies, Class Pattern en Class Matcher . . . 9
    8.1. Stringmethodes met reguliere expressies . . . 10
    8.2. Klasse Pattern en klasse Matcher . . . 11
9. Bijkomend leermateriaal . . . 12

1. Doelstellingen

- Kan strings verwerken in Java

2. Inleiding

- In dit hoofdstuk bespreken we de mogelijkheden van de klassen :
  - String
  - StringBuilder
  - Character
    Deze klassen vormen de basis voor string- en karakterbewerking in Java.
- En reguliere expressies
  - Met reguliere expressies kan je invoer valideren

3. Fundamenten van karakters en Strings

- Een karakter wordt intern opgeslagen door zijn overeenkomstige Unicode (zie Deitel - appendix B). Deze Unicode is een integerwaarde .
- Voorbeeld: char kar = 'z';
  Intern:

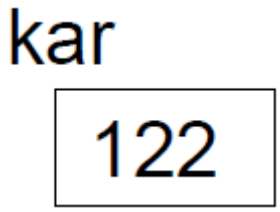

- Een string is een reeks van karakters die als één geheel wordt beschouwd. Kan bestaan uit letters, cijfers en speciale karakters.
- Een string is een object van de klasse String.
- Voorbeeld : String z = "Eddy Wally";
  Intern:

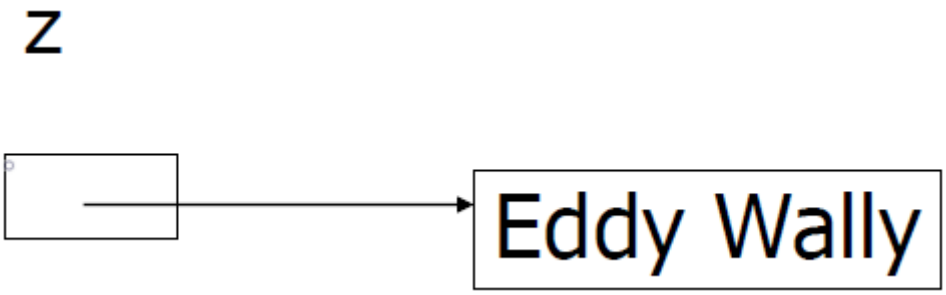

4. Klasse String

- De klasse String laat toe om Strings te creëren en te bewerken.
- Zie volledige klasse: https://docs.oracle.com/en/java/javase/index.html
- Klasse bevat o.a.
  - meerdere constructoren
  - methodes om Strings te vergelijken, om karakters en substrings in Strings te localiseren / extraheren, om Strings te concateneren, …

4.1. String constructoren

- s1 = new String(); → lege string (“”) met lengte 0

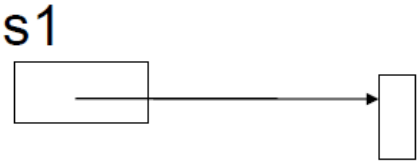

- s2 = new String(s);

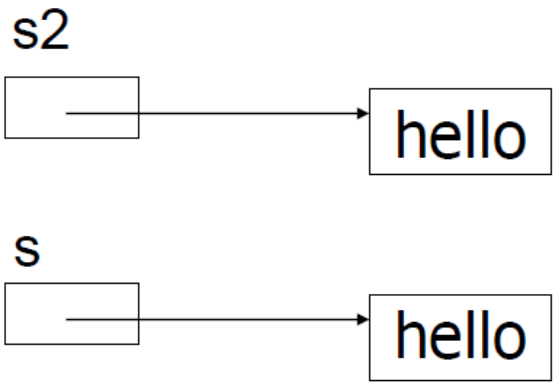

4.2. String literal versus String Object

- Zoals hierboven aangehaald zijn er 2 manieren om een string te creëren:
  - toekenning aan een string literal of
  - aanmaken van een String object via de new operator.
- Voorbeelden:
  - String s1 = "Hello";
  - String s2 = "Hello";
  - String s3 = s1;
  - String s4 = new String("Hello");
  - String s5 = new String("Hello");

Naargelang de gehanteerde werkwijze wordt de String op een andere manier bijgehouden in het geheugen:

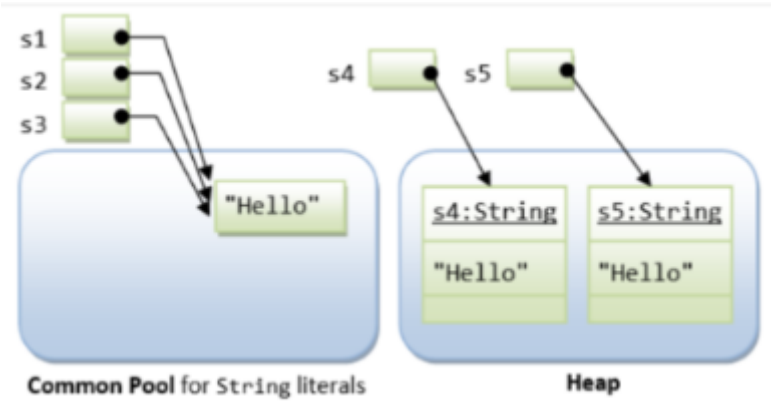

Figuur uit www3.ntu.edu.sg/home/ehchua/programming/java/J3D_String.html

String literals met dezelfde inhoud, delen dezelfde geheugenruimte in de zogenaamde string common pool. In de heap is niet zo en heeft elk String object zijn eigen geheugenruimte.

4.3. String methodes

- De methode **length()** geeft het aantal karakters van een String weer

```
s1.length() ⇒ methode
NIET s1.length zoals bij arrays ⇒ attribuut
```

- Het eerste karakter in een String begint steeds bij positie 0

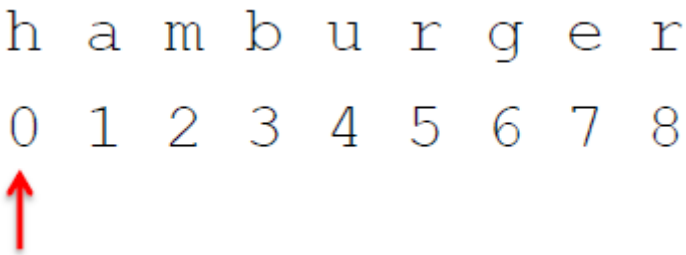

- De methode **charAt(pos)** geeft het karakter opde positie pos terug
- De methode **getChars(start,laatste,naar,vanafpos)** kopieert de karakters van een bepaalde String vanaf positie start t.e.m. laatste-1, in de array naar vanaf index vanafpos

4.4. Strings vergelijken

- Java voorziet een aantal methodes om String objecten met elkaar te vergelijken.
- Wanneer de computer twee strings met elkaar vergelijkt dan worden de interne numerieke codes van alle karakters in de strings met elkaar vergeleken.
  - String s1 is groter dan String s2
    ⇒ s1 komt alfabetisch na s2

- **equals()** test of de inhoud van twee strings identiek zijn (methode overgeërfd van de klasse Object)
  - Geeft true of false terug al naargelang alle karakters uit de String objecten gelijk zijn of niet (de Unicode waarden worden vergeleken).
- De **operator** == test of twee referentie variabelen naar hetzelfde object in het geheugen wijzen.
  - De adressen in de referentie variabelen naar de Strings worden vergeleken, niet de inhoud van de Strings!
- Voorbeeld:
  s1="hello"; ⇒ s1=="hello"?
  s1=new String("hello"); ⇒ s1=="hello"?
- **equalsIgnoreCase()** test of twee String objecten identiek zijn, maar houdt geen rekening met hoofd en kleine letters
  - Geeft true of false terug
- **compareTo()**
  - geeft 0 terug als de Strings dezelfde zijn of een negatief/positief getal terug als ze verschillend zijn:
    s1.compareTo(s2) = 0 als s1 en s2 gelijk zijn
    > 0 als s1 > s2
    < 0 als s1 < s2
- **regionMatches()** vergelijkt delen van twee Stringobjecten
  Voorbeeld: s1.regionMatches(0, s4, 0, 5)
  - vergelijk de vijf eerste karakters uit s1 met die van s4
    0 = start in s1
    0 = start in s4
    5 = aantal karakters
  - Geeft true of false terug
- **startsWith(string)**
  - Geeft true of false terug, al naargelang het String object begint met string.
- **endsWith(string)**
  - Geeft true of false terug, al naargelang het String object eindigt op string.

4.5. Karakters en substrings uit Strings

- De methode **indexOf** zoekt het eerste voorkomen van een karakter in een String.
  - Voorbeeld: letters.indexOf (‘c’)
    - geeft de index van het karakter c in de String letters weer, of
    - geeft -1 terug als het karakter niet in de String voorkomt
  - Voorbeeld: letters.indexOf (‘c’,7): idem, maar nu wordt pas gestart vanaf index 7 in letters
  - De methode indexOf kan ook gebruikt worden om een substring in een String te zoeken

- De methode **lastIndexOf** is analoog aan indexOf, alleen wordt nu het laatste voorkomen van een karakter weergegeven . Zoekt van achter naar voor in de String)
- De methode **substring** maakt een nieuwe String uit een bestaande String.
  - Voorbeeld: letters.substring(20)
    geeft een nieuwe String weer die een substring is van letters, beginnend vanaf index 20.
  - Voorbeeld: letters.substring(start, last)
    geeft substring uit letters terug , kopie van karakters van index start t.e.m. index last - 1
- De methode substring kan een StringOutOfBoundsException gooien

4.6. Concateneren van Strings

- De methode **concat** geeft een nieuwe String terug, die een concatenatie is van twee Strings.
  - Voorbeeld: s1.concat(s2)
    geeft een nieuwe String die een samenvoeging is van s1 en s2.
    s1 en s2 worden niet gewijzigd bij deze operatie

4.7. Andere String-methodes

- De methode **replace** geeft een nieuwe String terug, die een kopie is van de originele, maar waarin een bepaald karakter vervangen is door een ander karakter.
- De methode **toUpperCase** geeft een nieuwe String terug, die een kopie is van de originele, maar waarin alle karakters in hoofdletters staan.
- De methode **toLowerCase** geeft een nieuwe String terug, die een kopie is van de originele, maar waarin alle karakters in kleine letters staan.
- De methode **trim** geeft een nieuwe String terug, die een kopie is van de originele , maar waarin alle spaties vooraan en achteraan zijn verwijderd.
- De methode **toCharArray** kopieert alle karakters uit een String naar een array bestaande uit chars.

4.8. String methode valueOf

- De klasse String voorziet een aantal static klasse methodes, die argumenten van verschillende types kunnen converteren naar Strings.
  - De methode **valueOf** geeft een nieuwe String terug, die de String representatie voorstelt van een primitief datatype of ander object.

5. Klasse StringBuilder

- Nadat een String object gecreëerd is, kan de inhoud ervan nooit meer veranderen
- StringBuilder wordt gebruikt voor zogenaamde "dynamische strings" (dit is een aanpasbare versie van String)

- De capaciteit is het aantal karakters dat een StringBuilder kan bevatten
  - Als de capaciteit overtroffen wordt, dan breidt ze zich automatisch uit, om de bijkomende karakters te kunnen opvangen.
- Zie volledige klasse: https://docs.oracle.com/en/java/javase/index.html
- Gebruik + en += voor STRING concatenatie
  ⇒ De klasse StringBuilder wordt gebruikt om deze operatoren te implementeren.
  String string1 = "hello";
  String string2 = "BC";
  int value = 22;
  String s = string1 + string2 + value;
  ⇒ new StringBuilder().append("hello").append("BC").append(22).toString();

5.1. StringBuilder constructors

- Er zijn meerdere constructoren in de klasse StringBuilder, enkele voorbeelden :
  - buffer1 = new StringBuilder()
    Creëert een lege buffer met capaciteit van 16 karakters
  - buffer2 = new StringBuilder(lengte)
    Creëert een lege buffer met capaciteit het aantal karakters dat door de integer lengte wordt aangegeven
  - buffer 3 = new StringBuilder("tekst")
    Creëert een buffer met inhoud "tekst" en met capaciteit het aantal karakters in de string "tekst" + 16 dus in het vb.: 5 + 16 = 21

5.2. StringBuilder methoden

- Methode **length**
  - Geeft het aantal karakters in de StringBuilder terug
- Methode **capacity**
  - Geeft de capaciteit van de StringBuilder terug
  - capaciteit = aantal karakters dat kan opgeslagen worden zonder meer geheugenruimte te moeten alloceren
- Methode **setLength**
  - Verhoogt of verlaagt de lengte van de StringBuilder
- Methode **ensureCapacity**
  - Stelt de capaciteit van de StringBuilder in
  - Garandeert dat de StringBuilder een minimumcapaciteit heeft
  - Let op: als de originele capaciteit kleiner is dan de nieuwe, dan wordt de capaciteit ofwel het getal dat aangegeven wordt in het argument ofwel 2 * de originele capaciteit + 2, naargelang wat groter is

5.3. Methodes voor karakterbewerkingen

- Methode **charAt**
  - Geeft het karakter uit de StringBuilder terug dat zich op de gespecifieerde index bevindt
  - Indien de index buiten de grenzen van de StringBuilder valt , dan krijg je een StringIndexOutOfBoundsException
- Methode **setCharAt**
  - Vult het opgegeven karakter in de StringBuilder in op de gespecifieerde index
  - Zie charAt voor indexwaarde die buiten de grenzen valt
- Methode **getChars**
  - Geeft een array van karakters terug die overeenkomt met de inhoud van de StringBuilder
  - 4 argumenten : startindex , index 1 positie voorbij laatste te kopiëren karakter , de array waarnaar moet gekopieerd worden en de beginpositie in de array
- Methode **reverse**
  - Keert de inhoud van de StringBuilder om

5.4. Append methodes

- Meerdere overloaded **append** methodes om waarden van verschillende datatypes aan het einde van een StringBuilder te kunnen plakken
  - Een versie voor elk van de primitieve datatypes plus een voor karakterarrays, een voor Strings en een voor Objects

5.5. Tussenvoeg- en verwijdermethodes

- Methode **insert**
  - meerdere overloaded methodes om de verschillende datatypes te kunnen tussenvoegen op een gegeven positie in een StringBuilder
  - Twee argumenten: index en het in te voegen gedeelte
  - StringIndexOutOfBounds Exception bij verkeerde indexwaarde
- Methode **delete**
  - Wist een reeks karakters
  - Twee argumenten: startpositie en indexwaarde één positie voorbij het einde van de te wissen karakters
  - StringIndexOutOfBoundsException bij verkeerde indexwaarde
- Methode **deleteCharAt**
  - Wist één karakter
  - Eén argument: positie van het te wissen karakter

    - StringIndexOutOfBoundsException bij verkeerde indexwaarde

6. Klasse Character

- Primitieve variabelen als objecten behandelen
    - Klassen Boolean, Character, Double, Float, Byte, Short, Integer en Long
    - Behalve Boolean en Character worden deze klassen afgeleid van de klasse Number
    - Deze 8 klassen worden **"type wrappers"** genoemd en maken deel uit van java.lang
- Klasse Character: type wrapper voor karakters
    - Meeste methodes zijn static en testen of manipuleren een karakter
    - Constructor die aan de hand van een char argument een Character object maakt
    - Zie voorbeelden en Java API https://docs.oracle.com/en/java/javase/index.html documentatie voor meer informatie

7. Tokenizing Strings

- Token
    - Zie: Lezen van een zin
        - We delen de zin op in woorden en leestekens
        - Elk onderdeel (=token) heeft een betekenis voor ons
    - Compiler doet ook aan "tokenizing":
        - deelt statement op in keywords, identifiers, operators en andere elementen van de programmeertaal
- split methode:
    - Methode **split** van de klasse String verdeelt de zin in tokens en geeft een array van Strings terug.
        - Tokens worden gescheiden door **delimiters**
        - Dit zijn typisch whitespacekarakters zoals spatie, tab, newline, carriage return of een ander teken.
- Voorbeeld:

```
        Scanner scanner = new Scanner(System.in);
        System.out.println("Geef een zin en Enter");
        String zin = scanner.nextLine();

        String[] tokens = zin.split(" ");

        System.out.printf("Aantal elementen: %d%nTokens:%n", tokens.length);
        for(String token : tokens)
            System.out.println(token);
```

8. Reguliere expressies, Class Pattern en Class Matcher

- Een reguliere expressie is een String, een reeks van karakters en symbolen die een zoek “pattern” voorstelt om karakters te matchen in andere Strings.
- Dit is handig om:
  - invoer te valideren
  - na te gaan of data in een bepaald formaat staan
  - de syntax van een programma te valideren
- Gebruik: methode **matches** van de klasse String:
  - De parameter is een reguliere expressie, waarmee de inhoud van een String object wordt vergeleken
  - De teruggeefwaarde is een boolean, die aangeeft of de "match" is gelukt
- Voorbeelden:
  - if (postcode.matches("\\d{4}")) …
  - if(userId.matches("[a-z0-9]{5,10}")) …

Reguliere expressie syntax

Expressie	matches
\d	elk cijfer
\w	elke letter, cijfer of underscore
\s	elke witruimte
.	elk karakter, maar geen newline
\.	is een punt
\D	elk niet-cijfer
\W	elke niet-letter, niet-cijfer en geen underscore
\S	elke niet-witruimte
[…]	opsomming, [abc] ⇒ a of b of c
[^…]	^ negatie, [^abc] ⇒ alles behalve a, b en c
[A-Z]	- van tot en met ⇒ van A t.e.m. Z
re*	0 of meer
re+	1 of meer
re?	0 of 1
re{n}	precies n voorkomens
re{n,}	ten minste n voorkomens
re{n,m}	tussen n en m voorkomens
a|b	of ⇒ a of b
(re)	groeperen van reguliere expressies
^	begin van de lijn
$	einde van de lijn

8.1. Stringmethodes met reguliere expressies

- **replaceAll**:
  - vervangt in de String alle voorkomens van een bepaald stukje tekst door een nieuw stukje tekst
- **replaceFirst** :
  - vervangt alleen het eerste voorkomen van het stukje tekst door een nieuw stukje tekst
- **split**:
  - verdeelt een String in verscheidene substrings

8.2. Klasse Pattern en klasse Matcher

- Klasse **Pattern** stelt een reguliere expressie voor
- Klasse **Matcher** bevat
  - een reguliere expressie pattern
  - een **CharSequence** waarin gezocht wordt naar een pattern
- CharSequence is een interface ⇒ methodes charAt , length , subSequence en toString moeten worden gedeclareerd . De klassen String, StringBuilder , … implementeren deze interface.
- Pattern klasse
  - Eénmaal reguliere expressie gebruiken ⇒ static Pattern methode **matches**
  - Meerdere keren reguliere expressie gebruiken ⇒ static Pattern methode **compile**
- Matcher klasse
  - matches, idem matches uit Pattern, maar ontvangt geen argumenten
  - find, lookingAt, replaceFirst en replaceAll
  - Voorbeeld :

```
    public static void main(String args[]) {
        String REGEX = "a*b";
        String INPUT = "aabfooaabfooabfoob";

        Pattern p = Pattern.compile(REGEX);
        Matcher m = p.matcher(INPUT); // get a matcher object
        int count = 0;

        while (m.find()) {
            System.out.println("Match " + ++count);
            System.out.println(m.group());

        }
    }
```

Geeft als uitvoer:

```
Match 1
aab
Match 2
aab
Match 3
ab
Match 4
b
```

9. Bijkomend leermateriaal

- http://docs.oracle.com/javase/tutorial/java/data/strings.html
- http://docs.oracle.com/javase/tutorial/java/data/characters.html
- https://docs.oracle.com/javase/tutorial/essential/regex/index.html